

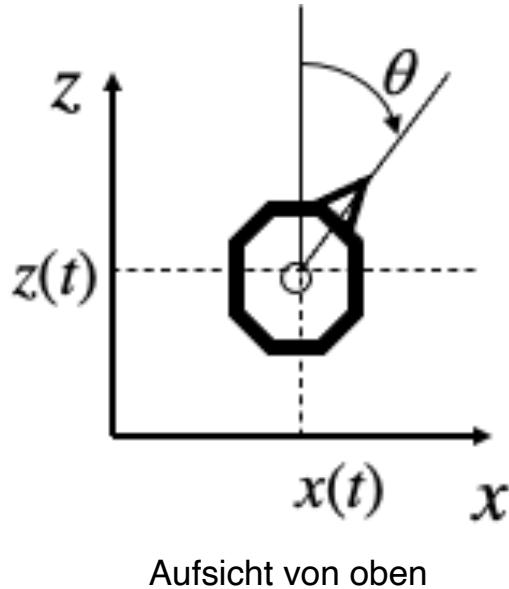
# Robotik

Priv.-Doz. Dr. Thomas Wiemann  
Institut für Informatik  
Autonome Robotik

SoSe 2021



## Wdh: Basisodometrie für Diff'antrieb



$$\begin{aligned} dx/dt &= v \sin(\theta_t) = [(v_R + v_L)/2] \cdot \sin(\theta_t) \\ dz/dt &= v \cos(\theta_t) = [(v_R + v_L)/2] \cdot \cos(\theta_t) \end{aligned}$$

$$\theta_t = \theta_0 + \frac{(v_L - v_R)t}{b}$$

- ▶ Die Differenzmessung zwischen  $v_L, v_R$  ist fehlerbehaftet
- ▶ Bei kleiner Differenz ( $v_L - v_R$ ) numerisch instabil
- ▶ Approximiere Pose über die Zeit  $\Delta t$
- ▶ Während  $\Delta t$  seien:

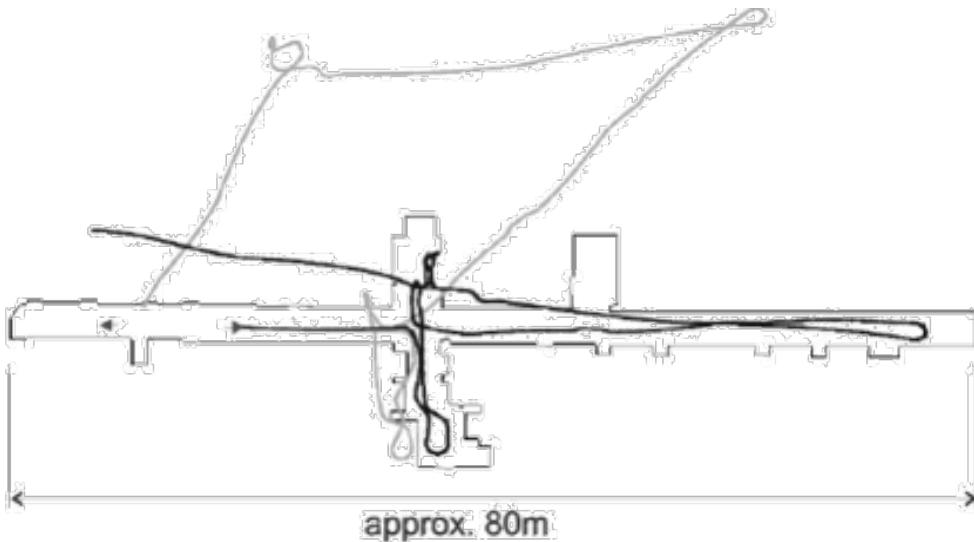
$$v = (v_R + v_L)/2$$

$$\Delta\theta = (v_L - v_R)/b$$

$$\begin{bmatrix} x_n \\ z_n \\ \theta_n \end{bmatrix} = \begin{bmatrix} x_{n-1} \\ z_{n-1} \\ \theta_{n-1} \end{bmatrix} + \begin{bmatrix} v \cdot \Delta t \cdot \sin(\theta_{n-1} + \frac{\Delta\theta}{2} \Delta t) \\ v \cdot \Delta t \cdot \cos(\theta_{n-1} + \frac{\Delta\theta}{2} \Delta t) \\ \Delta\theta \cdot \Delta t \end{bmatrix}$$

- ▶ Alternativen:
  - vereinfacht nur  $v \cdot \Delta t \cdot \sin \theta$  bzw.  $v \cdot \Delta t \cdot \cos \theta$
  - Kalibrierbares Fehlermodell für  $x, z$  (z.B. für Ceres)

## Wdh.: Ergebnisse Qualitativ



### Beispiel:

- Flurfahrt ca. 200m mit KURT2

Für kurze, besonders gerade Strecken ist sie okay!  
Fusioniert mit anderen Sensordaten ist sie hilfreich!

- ▶ Lokalisierung nach Odometrie (Koppelnavigation) ist kostenlos
- ▶ Sie unterliegt gravierenden systematischen Fehlern
- ▶ Variabler Schlupf (auch des Zahnriemens, KURT2), Kurvenmodell, ...)
- ▶ Billige empirische Verbesserungen machen Sinn
- ▶ Fehler akkumulieren über die Zeit unbegrenzt



## Gliederung

### 5. Fortbewegung

1. Einleitung
2. Bewegungsschätzung
- 3. Bayes- und Kalmanfilter**
- 4. Fusion von Odometriedaten**
6. Lokalisierung
7. Mapping
8. Navigation
9. Ausblick

# Wdh.: Ereignis, Variable

**Ergebnisraum**  $\Omega$ : Mögliche Ergebnisse eines Zufallsexperiments

z.B.:  $\{,,1“,,,2“,,,3“,,,4“,,,5“,,,6“\}$  beim Würfeln  
 $\{[,,1“,sonnig], [,,1“,regnet], [,,2“,sonnig], …, [,,6“,regnet]\}$

**Ereignis**:

Teilmenge v.  $\Omega$ . z.B.:  $\{,,2“,,,4“,,,6“\}$  beim Würfeln („gerade“)

**Elementarereignis**:

$\omega \in \Omega$ . (eigentlich: einelementiges Ereignis) z.B.:  $[,,1“,sonnig]$

**Zufallsvariable**: Funktion von Elementarereignissen  $\omega \in \Omega$  in einen Wertebereich  $\mathcal{D}$ . (Notation: beginnt mit Großbuchstabe)

$\mathcal{D}=\{\text{true}, \text{false}\}$ : **Boolesche** Zufallsvariable, z.B.: *Zahnloch*

$\mathcal{D}$  diskret: **Diskrete** ZV, z.B.: *Augenzahl* (auf einem Würfel)

$\mathcal{D}$  stetig (hier:  $\mathfrak{R}$ ): **kontinuierliche** ZV, z.B.: *Position* (Roboter im 2D)

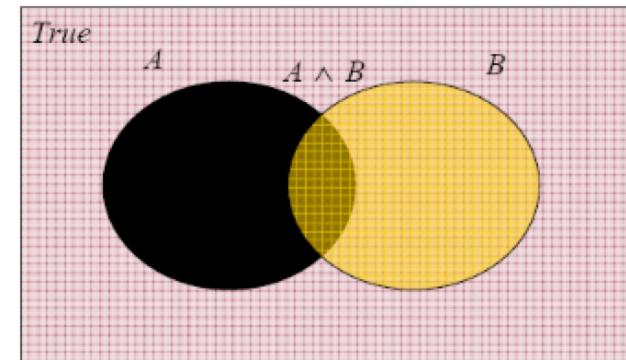
## Wdh.: Wahrscheinlichkeitsraum

**Wahrscheinlichkeitsraum ( $\Omega, P$ )**,  $\Omega \neq \emptyset$ :  $P$  ist eine so auf Ereignissen aus  $\Omega$  definierte reellwertige Funktion („Wahrscheinlichkeit“), dass die **Kolmogorow-Axiome** gelten:

1.  $0 \leq P(e) \leq 1$  für alle  $e \subseteq \Omega$
2.  $P(\Omega) = 1$
3. Für  $d, e \subseteq \Omega$  gilt:  $P(d \cup e) = P(d) + P(e) - P(d \cap e)$

z.B.:  $P(\text{,,gerade"}) = P(\text{,,2"}) + P(\text{,,4"}) + P(\text{,,6"}) = 1/6 + 1/6 + 1/6 = 1/2$

(W'raum präziser  $(\Omega, \Sigma, P)$  mit Ereignisraum  $\Sigma$  – hier verkürzt dargestellt)



Ereign.  $a, b$  sind **unabhängig** auf  $(\Omega, P)$ , gdw:

$$P(a \cap b) = P(a) \cdot P(b)$$

$P$  induziert Funktionen auf den Zufallsvariablen über  $(\Omega, P)$ :

## Wahrscheinlichkeitsverteilung $P$ einer diskreten

Zufallsvariablen  $X$ : Liste aus W'keiten der möglichen

Werte für  $X$ , wobei  $\sum_{x \in \text{Range}(X) \subseteq \Omega} P(x) = 1$

z.B.:  $P(\text{Augenzahl}) = \langle P(„1“), \dots, P(„6“) \rangle =$   
 $\langle 1/6, 1/6, 1/6, 1/6, 1/6, 1/6 \rangle$

**Notation:**  $P(\text{Augenzahl} = „1“) = 1/6$

## Wahrscheinlichkeitsdichte $P$ einer kontinuierlichen

Zufallsvariablen  $X$ : Fkt. vom Typ  $\text{Range}(X) \rightarrow [0,1]$ , wobei

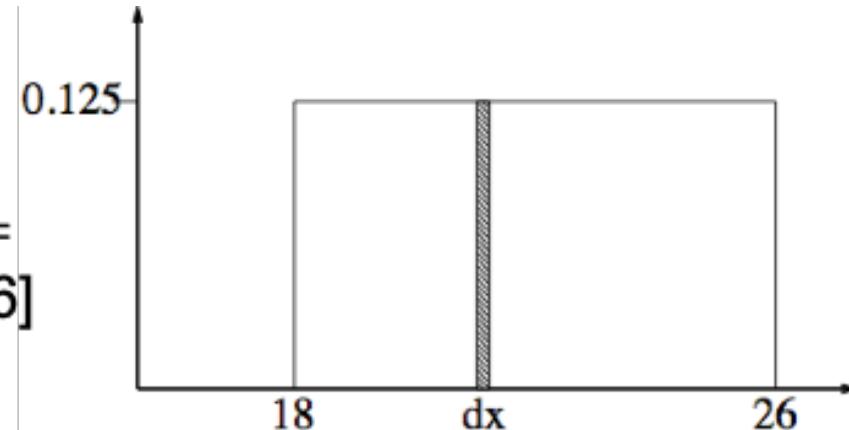
$$\int_{x \in \text{Range}(X) \subseteq \Omega} P(x) dx = 1$$

und  $P(a \leq x \leq b) = \int_a^b P(x) dx$

z.B.: ...

## Beispiel für Wahrscheinlichkeitsdichte

$\mathbf{P}(\text{Temperatur}) = U[18,26](x) =$   
**Gleichverteilung** auf [18,26]



$$\int_{-\infty}^{\infty} U[18,26](x)dx = \int_{18}^{26} U[18,26](x)dx = 1$$

$$\mathbf{P}(20 \leq \text{Temperatur} \leq 22) = \int_{20}^{22} U[18,26](x)dx = 0,25 = P(\dots)$$

$$P(20,5) = 0$$

$$\mathbf{P}(\text{Temperatur}=20,5) = \lim_{dx \rightarrow 0} \mathbf{P}(20,5 \leq X \leq 20,5+dx)/dx = 0,125/\text{°C}$$

# Unbedingte Wahrscheinlichkeiten

W'keit  $P$  „an sich“, ohne weitere Information:

**Unbedingte** Wahrscheinlichkeit (**a priori** W'keit)

z.B.:  $P(\text{regnet}) = 0,3$

Verteilung für unbedingte W'keiten wie beschrieben

z.B.:  $\mathbf{P(OSWetter)} = \langle P(\text{sonnig}), P(\text{wolkig}), P(\text{regnet}), P(\text{frostig}) \rangle$   
 $= \langle 0,25, 0,4, 0,3, 0,05 \rangle$

**Gemeinsame Verteilung** von  $n$  ZVen entspricht  $n$ -dim. Tabelle:

**Notation:**  $\mathbf{P}(ZV_1 \cap ZV_2)$   
oder  $\mathbf{P}(ZV_1, ZV_2)$

**Beispiel:**  
 $\mathbf{P(OSWetter, Zahnloch)}$

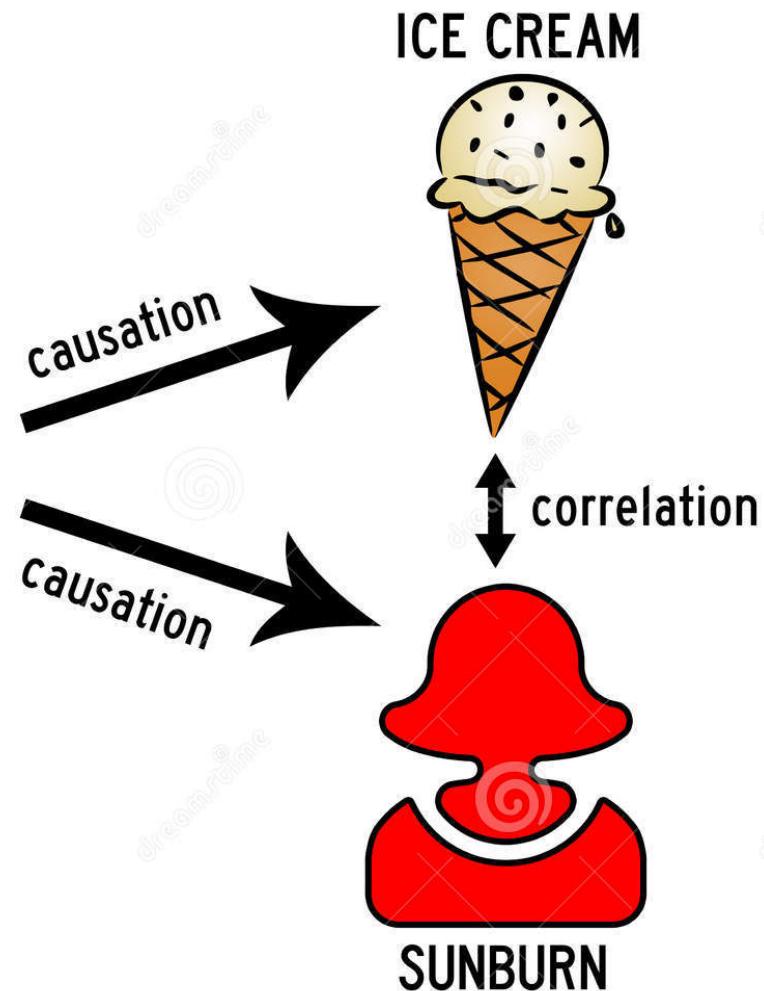
$OSWetter =$ <i>Zahnloch =</i>	<i>sonnig</i>	<i>wolkig</i>	<i>regnet</i>	<i>frostig</i>
<i>false</i>	0,225	0,36	0,27	0,045
<i>true</i>	0,025	0,04	0,03	0,005

**Vollständige gem. Verteilg.:** W'keit aller Elementarereignisse  
(hat  $O(m^n)$  Einzelw'keiten für  $n$  ZVen mit max.  $m$  Werten)

# Kausalität und Korrelation



DRY, HOT AND SUNNY  
SUMMER WEATHER



# Bedingte Wahrscheinlichkeiten

W'keit  $P$  bei gegebener Information:

**Bedingte** Wahrscheinlichkeit (**a posteriori** W'keit)

z.B.:  $P(\text{regnet} \mid \text{lufldruck\_hoch}) = 0,1$

**Definiert** (falls  $P(b) > 0$ ) als  
 $(P(a|b)=0, \text{ falls } P(b)=0)$  
$$P(a \mid b) := \frac{P(a \cap b)}{P(b)}$$

... oder als („Produktregel“):  $P(a \cap b) = P(a|b)P(b) = P(b|a)P(a)$

z.B.:  $P(\text{sonnig} \neg \text{zahnloch}) = 0,225 / 0,9 = 0,25$   
entspricht  $P(\text{sonnig})$ , weil unabhängig!

Entsprechend für W'verteilungen:

$$\mathbf{P(OSWetter, Zahnloch)} = \mathbf{P(OSWetter|Zahnloch)} \mathbf{P(Zahnloch)}$$

## Bedingte Unabhängigkeit

Zwei Ereignisse  $a, b$  sind **bedingt unabhängig**, gegeben  $c$ ,  
gdw.:

$$P(a,b \mid c) = P(a \mid c) P(b \mid c)$$

Zwei Zufallsvariable  $A, B$  sind **bedingt unabhängig**, geg.  $C$ ,  
gdw.:

$$\mathbf{P}(A, B \mid C) = \mathbf{P}(A \mid C) \mathbf{P}(B \mid C)$$

Damit äquivalent sind die Formulierungen

$$\mathbf{P}(A \mid B,C) = \mathbf{P}(A \mid C) \text{ und } \mathbf{P}(B \mid A,C) = \mathbf{P}(B \mid C)$$

→ kleinere Verteilungen ohne volle Unabhängigkeit!!

# Die Bayes'sche Regel

Erinnerung Produktregel:  $P(a \cap b) = P(a|b)P(b) = P(b|a)P(a)$

„Satz“ von Bayes

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)} = \alpha \cdot P(a|b)P(b)$$

... oder für Verteilungen:

$$\mathbf{P}(Y|X) = \frac{\mathbf{P}(X|Y)\mathbf{P}(Y)}{\mathbf{P}(X)} = \alpha \cdot \mathbf{P}(X|Y)\mathbf{P}(Y)$$

... oder bei vorhandener Evidenz e (Messungen oft  $\mathbf{z}$  genannt!):

$$P(y|\mathbf{z}) = P(y|z_1, \dots, z_n) = \frac{P(z_n|y, z_1, \dots, z_{n-1})P(y|z_1, \dots, z_{n-1})}{P(z_n|z_1, \dots, z_{n-1})}$$

## Anwendung: Diagnoseregeln

$$P(\text{ursache} \mid \text{wirkung}) = \frac{P(\text{wirkung} \mid \text{ursache}) \cdot P(\text{ursache})}{P(\text{wirkung})}$$

Oft sind kausale Zusammenhänge besser bekannt  
als diagnostische

### Verwendung in der Robotik

$$P(\text{Zustand} \mid \text{Messung}) = \frac{P(\text{Messung} \mid \text{Zustand}) \cdot P(\text{Zustand})}{P(\text{Messung})}$$

### Beispiel

$$P(\text{Briefbox} = \text{voll} \mid \text{Fahne} = \text{hoch}) = \frac{P(\text{Fahne} = \text{hoch} \mid \text{Briefbox} = \text{voll}) \cdot P(\text{Briefbox} = \text{voll})}{P(\text{Fahne} = \text{hoch})}$$

## Totale Wahrscheinlichkeit, Marginalisierung

- ▶ Gegeben seien  $n$  paarweise disjunkte Ereignisse  $B_1, B_2, \dots, B_n$  mit  $P(B_i) > 0$  für alle  $i$
- ▶ Wir kennen nur bedingte Wahrscheinlichkeiten und die a-priori-Wahrscheinlichkeiten der  $B_i$
- ▶ Wir suchen: die totale Wahrscheinlichkeit eines Ereignisses  $A$
- ▶ Es gilt:

$$P(A) = \sum_B P(A, B)$$

$$P(A) = \int P(A, B) db$$

$$P(A) = \sum_B P(A | B) \cdot P(B)$$

$$P(A) = \int P(A | B) \cdot P(B) db$$

# Erwartungswert

## Erwartungswert

(e. numerischen diskreten ZV)

$$E(X) = \sum_i x_i \cdot P(X = x_i)$$

- repräsentiert „erwartetes“ Ergebnis e. zufälligen Messung
- i.a. nicht dasselbe wie Mittelwert!

## Beispiele

- Würfel:  $E(\text{Augenzahl}) = 1/6 \cdot (1+2+3+4+5+6) = 3,5$
- Münze:  $E(\text{Münzwurf}) = 1/2 \cdot (0+1) = 0,5$
- bei gleichverteilter ZV ist E-Wert gleich Mittelwert

# (Ko)Varianz, Korrelation

**Varianz** ist „Streuung der Abweichung vom Erwartungswert“:

$$V(X) = \sigma_X^2 := E((X - E(X))^2)$$

**Kovarianz** ist „Zusammenhang“ zweier ZV:

$$\sigma_{XY} = E(XY) - E(X)E(Y) = E((X - E(X))(Y - E(Y)))$$

- positiv bei gleichsinnigem Zusammenhang
- negativ bei gegensinnigem
- 0 bei fehlendem Zusammenhang  
(≠Unabhängigkeit! Aber: Wenn unabhängig, dann Kovarianz = 0)

**Korrelation** ist auf [-1,1] normierte Kovarianz

Eine **Kovarianzmatrix**  $\Sigma$  listet d. Kovarianzen aller Paare einer Menge v. ZV  $X_1, \dots, X_n$ .  
(Symmetrisch, da  $\sigma_{ik} = \sigma_{ki}$ ; ( $\sigma_{ii} = \sigma_i^2$ ) )

$$\begin{pmatrix} \sigma_{11} & \cdots & \sigma_{1n} \\ \vdots & \ddots & \vdots \\ \sigma_{n1} & \cdots & \sigma_{nn} \end{pmatrix}$$

# Gaußverteilung

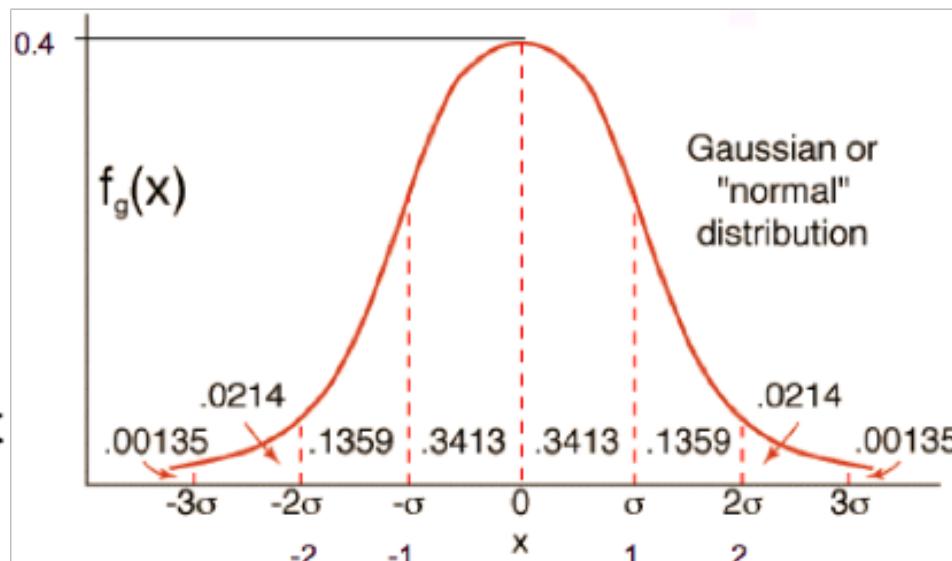
**Gaußverteilung** mit Mittelwert  $\mu$  und Standardabweichung  $\sigma$ :

$$P(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

**Standard-Normalverteilung** ( $\mu=0, \sigma=1$ ):  $P(x) = e^{-x^2/2}/\sqrt{2\pi}$

$$\begin{aligned} P(\mu-\sigma < X \leq \mu+\sigma) &\approx 0.68 \\ P(\mu-2\sigma < X \leq \mu+2\sigma) &\approx 0.955 \\ P(\mu-3\sigma < X \leq \mu+3\sigma) &\approx 0.997 \end{aligned}$$

Standardabweichung  $\sigma$  ist die Wurzel der Varianz



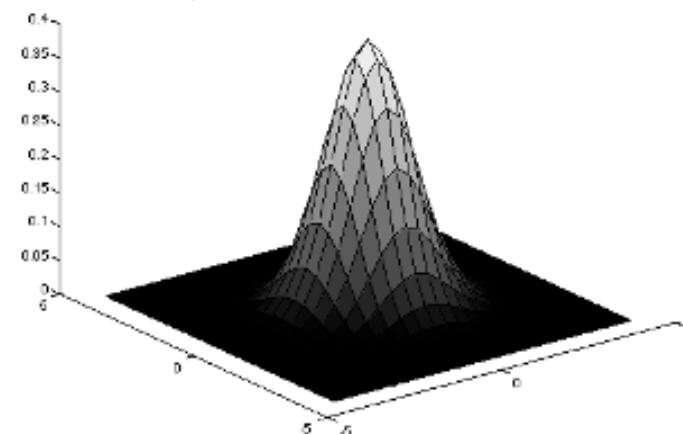
# Multivariate Gaußverteilungen

$$\mathbf{P}(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$$

... sind direkte Verallgemeinerungen eindimensionaler Gaußverteilungen auf  $n$ -dim. Vektor  $\mathbf{x}$  für eine  $n$ -dim. Kovarianzmatrix  $\Sigma$ , wobei für Skalar  $x$  (also  $n=1$ ) gilt:  $\Sigma=\sigma^2$

$$\mathbf{P}(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n \cdot \text{Det}(\Sigma)}} e^{-\frac{1}{2} ((\mathbf{x}-\mu)^T \Sigma^{-1} (\mathbf{x}-\mu))}$$

(Nach Konstruktion:  
 $\Sigma$  invertierbar,  $\text{Det}(\Sigma) \neq 0$ !  
**Erinnerung:**  $\text{Det}(r)=r$ )



# Stichprobenziehen gemäß Verteilung

... werden wir immer mal wieder brauchen

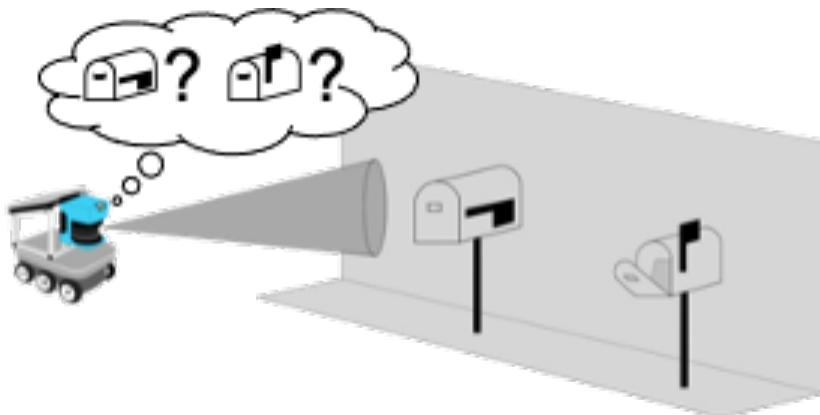
... ist ein klassisches Problem in der Statistik

(„.... Umfrage unter 1001 repräsentativ ausgewählten Dalmatinern“, „.... Sitzverteilung nach d'Hondtschem Verfahren aus Wählerstimmen“, ...)

## Grundidee theoretisch:

- Aufrufe `random` approximieren Gleichverteilung auf  $[0,1]$
- Stichproben  $S_{1,\dots,N}$  gleichverteilt auf  $[0,1]$  (bzw.  $(0,1)$ ) lassen sich umrechnen auf beliebige Verteilung  $\mathbf{P}$ 
  - Wert nach  $\mathbf{P}$  von  $S_i$  ist  $x_i$  für das gilt: 
$$S_i = \int_{-\infty}^{x_i} \mathbf{P}(x) dx$$

# Probabilistische Robotik - Briefkastenbeispiel



Ist Post da?

oder:

$$P(S|E) = \frac{P(E|S)P(S)}{P(E)}$$

- ▶ Für Briefkasten betrachte die Zufallsverteilung  $S$  mit  $\mathcal{D}(S) = \{l, v\}$  (leer bzw. voll)
- ▶ Evidenzen  $E$  mit  $\mathcal{D}(E) = \{e_l, e_v\}$
- ▶ Gegeben (lange Erfahrung!) seien:

$$P(S) = \langle P(l), P(v) \rangle = \langle 0.5, 0.5 \rangle$$

$$\begin{aligned} P(E|S) &= \langle P(e_l|l), P(e_l|v), P(e_v|v), P(e_v|l) \rangle \\ &= \langle 0.7, 0.2, 0.8, 0.3 \rangle \end{aligned}$$

- ▶ z.B.:  $P(l|e_l) = \frac{P(e_l|l)P(l)}{P(e_l)} = \frac{0.7 \cdot 0.5}{P(e_l)}$
- ▶ Kennen wir  $P(e_l)$  ? Ja:  $P(e_l) = P(e_l|l)P(l) + P(e_l|v)P(v) = 0.35 + 0.1$   
(Marginalisierung) ↗  $P(l|e_l) = 0.7778$

# Statistische Unabhängigkeit

- ▶ Löst “schräfer Hingucken” Unsicherheit auf?
- ▶ Extrembeispiel: Nutze die selbe Information mehrmals
  - ▶ Intuition sagt: “Das kann nichts bringen!”
  - ▶ Wahrscheinlichkeitstheorie sagt: “Stimmt!”

$$P(a|b,b) = P(a|b)P(b|b) = P(a|b)$$

Messungen müssen **statistisch unabhängig** sein:  
 $P(a \cap b) = P(a) \cdot P(b)$  also  $P(a|b) = P(a)$  und  $P(b|a) = P(b)$

- ▶ Messungen „desselben“ an derselben Stelle sind abhängig
- ▶ Modelliere alle Messungen eines Zustands als eine Messung
- ▶ Auch konsekutive Messungen auf Robotern
- ▶ (z.B. bei Lokalisierung) sind statistisch meist nicht unabhängig
- ▶ Praktisch kümmert man sich meist nicht darum!

## Bayes-Filter: Modell (1)

- ▶ Gesucht: evidenzbasierte Zustandsschätzung

$$P(X_{t+1} | e_{1:t+1}) = f(e_{1:t+1}, P(X_t | e_{1:t}))$$

- ▶ Für irgendeine Funktion  $f$  und Evidenzen (Aktion oder Messung)  $e$
- ▶ Unter der **Markov-Annahme**: Eine Evidenz ist unabhängig von allen anderen, gegeben der aktuelle Zustand
- ▶ Ansatz:

$$\begin{aligned}
 P(X_{t+1} | e_{1:t+1}) &= P(X_{t+1} | e_{1:t}, e_{t+1}) \\
 &= \eta \cdot P(e_{t+1} | X_{t+1}, e_{1:t}) \cdot P(X_{t+1} | e_{1:t}) && [\text{Bayessche Regel}] \\
 &= \eta \cdot \underbrace{P(e_{t+1} | X_{t+1})}_{\text{Filterung}} \underbrace{P(X_{t+1} | e_{1:t})}_{\text{Prädiktion}} && [\text{Markow-Annahme}]
 \end{aligned}$$

## Bayes-Filter: Modell (2)

- ▶ Vereinfachung der Prädiktion:

$$\begin{aligned}
 P(\mathbf{X}_{t+1} | \mathbf{e}_{1:t}) &= \int_{\mathbf{x}_t} [P(\mathbf{X}_{t+1} | \mathbf{x}_t, \mathbf{e}_{1:t}) \cdot P(\mathbf{x}_t | \mathbf{e}_{1:t})] \\
 &= \int_{\mathbf{x}_t} [P(\mathbf{X}_{t+1} | \mathbf{x}_t) \cdot P(\mathbf{x}_t | \mathbf{e}_{1:t})]
 \end{aligned}$$

[Markow-Annahme]

Aktuelle Wahrscheinlichkeit  
für Zustand

- ▶ Zusammengefasst:

$$P(\mathbf{X}_{t+1} | \mathbf{e}_{1:t+1}) = \eta \cdot P(\mathbf{e}_{t+1} | \mathbf{X}_{t+1}) \cdot \int_{\mathbf{x}_t} [P(\mathbf{X}_{t+1} | \mathbf{x}_t) \cdot P(\mathbf{x}_t | \mathbf{e}_{1:t})]$$

- ▶ So nicht praktikabel:
  - kontinuierliche Verteilungen, Integration
- ▶ Unterschiedliche Vereinfachungen / Approximationen möglich

# Spezieller Bayes-Filter (Idee)

- Voraussetzung: Roboterhandeln + Umgebungs dynamik wird beschrieben als Folge von abwechselnd Aktion / Ereignis und Zustandsmessung, gegeben Start-Zustandsschätzung

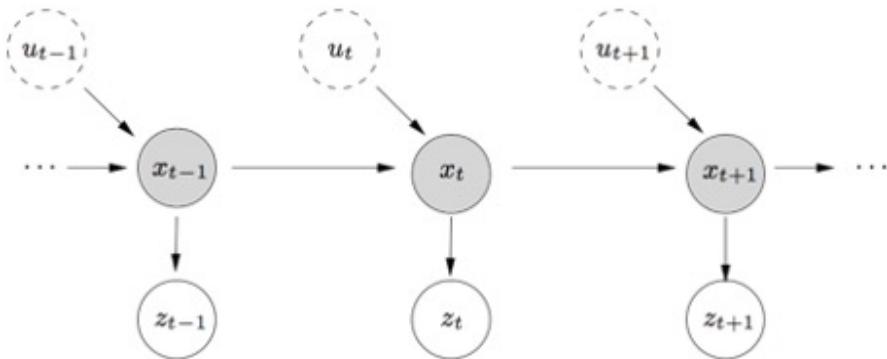
## 1. Prädiktion:

- Sage resultierenden Zustand für Aktion/Ereignis im aktuellen Zustand voraus (**a-priori-Zustandsschätzung**)
- (z.B. berechne erwartete Zielpose für Fahrbefehl);
- führe die Aktion aus (bzw. das unabhängige Ereignis geschieht)

## 2. Filterung:

- Miss resultierenden Zustand; ggf. mach mehrere unabhängige Messungen (die sich widersprechen dürfen)
- z.B. miss Pose durch Odometrie und durch IMU;
- berechne aktuelle Zustandsverteilung, die maximal gut zu allen Messungen und der Vorhersage passt (**a-posteriori-Zustandsschätzung**)
- weiter bei 1.

# Handeln und Messen



- ▶ Erzielle Unabhängigkeit durch Abwechseln von Messen-Handeln-Messen-Handeln-...
- ▶ **Konvention:** Sortiere Evidenzen in Aktionen  $u_i$ , Messungen  $z_i$
- ▶ **Konvention:** Wahrscheinlichkeit des Zustands  $x$  heißt  $Bel(x)$  ("Belief")

$$Bel(x_t) = P(x_1 | u_1, z_1, \dots, u_t, z_t)$$

- ▶ Vereinfachung: Diskrete Zustände  $\rightarrow$  Ersetze  $\int$  durch  $\sum$

$$Bel(x_t) = \eta P(z_t | x_t) \sum_{x_{t-1}} P(x_t | x_{t-1}, u_t) \cdot Bel(x_{t-1})$$

(Statisches) Sensormodell

Aktionsmodell

## Briefkastenbeispiel (2)

- Aktion *leeren* leert den Briefkasten (meistens):

$$\mathbf{P}(S \mid \text{leeren}, S^-) =$$

$$= \langle P(l \mid \text{leeren}, v), P(v \mid \text{leeren}, v), P(l \mid \text{leeren}, l), P(v \mid \text{leeren}, l) \rangle \\ := \langle 0.8, 0.2, 1, 0 \rangle$$

- Gelte für Anfangszustand  $x_0$ :

$$Bel(x_0 : S=v) = P(v) := 0.75$$

- Führe Aktion *leeren* zum Zustand  $x_1$ . Dann gilt a priori:

$$Bel(x_1 : S=l) = \sum_S P(l \mid \text{leeren}, S) \cdot Bel(x_0 : S) \\ = P(l \mid \text{leeren}, v) \cdot P(v) + P(l \mid \text{leeren}, l) \cdot P(l) \\ = 0.8 \cdot 0.75 + 1 \cdot 0.25 = 0.85$$

$$Bel(x_1 : S=v) = 1 - Bel(x_1 : S=l) \quad (\text{Nachprüfen zur Übung!})$$

Hier Belief noch ohne Messung → a-posteriori-Schätzung  
analog dem 1. Beispiel-Teil mit Normalisierung